Python与金融数据挖掘(6)

文欣秀

wenxinxiu@ecust.edu.cn

案例分析


finance.sina.com.cn
新浪首页 >> 蔡崇信反思阿里 海通国际巨亏从何而来 金价再创纪录新高
sina 新浪财经
手机版
新浪财经APP 新浪科技 投教基地
黑猫投诉
领跑者
免费试用
买基
股票 新股 港股 美股 基金 期货 外汇 黄金 债券 理财 银行 保险 信托 医药 科创板 ESG
环球股指 黄金 原油 投研中心 新浪财经APP
行情
简称/代码/拼音
sina 新浪财经
打破信息不对称
7x24快讯
16:33
采纳股份：美国FDA宣布对全资子公司发出…

简单爬虫程序基本步骤

- 获取网页源码
- 根据源码中所在链接特点写出正则表达式
- 用正则对象匹配获取目标链接
- 用循环结构遍历目标链接并自动下载信息

Requests对象的属性

属性	说明
r. text	网页响应内容的**字符串**形式
r. encoding	**猜测**网页响应内容编码方式
r. apparent_encoding	从网页内容**分析**出编码方式
r. content	网页响应内容的**二进制**形式
r.status_code	**200**表示连接**成功**，404表示失败

爬取网页内容并存入文件

```
import requests
url="https://finance.sina.com.cn/"
r=requests.get(url)
r.encoding=r.apparent_encoding
data=r.text
fobj=open("result.txt", "w", encoding="utf-8")
fobj.write(data)
fobj.close()
```

爬取单个PDF文件

```
import requests
url="https://ir.mi.com/system/files-encrypted/nasdaq_kms/assets/\
2023/05/24/6-15-10/2023052400738_c.pdf"
r=requests.get(url)
data=r.content
fobj=open("小米2023第一季度公告.pdf","wb")
fobj.write(data)
fobj.close()
```

问题： 如何获取多个pdf文档内容?

正则表达式

正则表达式（regular expression，re）:是由一些**特定字符**及其**组合**所组成的**字符串表达式（模板）**，用来对目标字符串进行过滤操作。处理正则表达式需要引入**标准库是re**。

re库的内置函数

- match()：用于从起始位置匹配
- search()：搜索整个字符串，返回第一次出现位置
- **findall()**：以列表形式返回全部能匹配的字串
- compile()：创建一个正则表达式对象

内置函数示例

```
>>> import re
>>> string="I love ECUST. ECUST loves me."
>>> re. match("I", string)
>>> re. match("ECUST", string)
>>> re. search("I", string)
>>> re. search("ECUST", string)
```

内置函数示例

```
>>> import re
>>> string="I love it. It loves me."
>>> result=re. findall("it", string)
>>> print(result)
```

问题： 如何实现不区分大小写？

正则表达式修饰符含义

修饰符	描述
re.I	使匹配对大小写不敏感
re.L	做本地化识别（locale-aware）匹配
re.M	多行匹配，影响 ^ 和 $
re.S	使 . 匹配包括换行在内的所有字符
re.U	根据Unicode字符集解析字符。这个标志影响 \w, \W, \b, \B.
re.X	该标志通过给予你更灵活的格式以便你将正则表达式写得更易于理解。

内置函数示例

```
>>> import re
>>> string="I love it. It loves me."
>>> test=re. compile("it", re.I)
>>> result=re. findall(test, string)  #result=test. findall(string)
>>> print(result)
```

问题：如何实现查找所有以e结尾的单词？

字符串匹配表

模式	描述
\d	匹配一个数字字符
\w	匹配一个字母、数字及下划线字符
\s	匹配一个空白字符
.	匹配一个任意字符，换行符除外
\n	匹配一个换行符
\t	匹配一个制表符

字符串匹配表

模式	描述
*	匹配前面的字符0次或n次
+	匹配前面的字符1次或n次
?	匹配前面的字符0次或1次
()	匹配括号内表达式，也表示一个组
{m, n}	匹配m-n个字符
[]	表示字符范围，方括号中只能取一个

字符串匹配模式

字符串匹配通常分为贪婪匹配和非贪婪匹配。

贪婪匹配：是一种尽可能多地匹配字符的匹配模式，是正则表达式默认匹配方式

例如：在匹配字符串"aaaaaa"时，'a{2,4}'默认取上限，匹配4个'a'

非贪婪匹配：一种尽可能少地匹配字符的模式

'**a{2,4}?**'取下限，匹配2个'a'

贪婪匹配模式示例

```
import re
res = '文本A百度新闻文本B，文本A新浪财经文本B，文本A搜狐新闻文本B'
p_source = '文本A(.*)文本B'
source = re.findall(p_source, res)
print(source)
```

['百度新闻文本B，新闻标题 文本A新浪财经文本B，文本A搜狐新闻']

非贪婪匹配模式示例

```
import re
res = '文本A百度新闻文本B，文本A新浪财经文本B，文本A搜狐新闻文本B'
p_source = '文本A(.*?)文本B'
source = re.findall(p_source, res)
print(source)
```

['百度新闻', '新浪财经', '搜狐新闻']

正则表达式示例

```
import re
s='''<img src="C:\\XH.jpg" width="300"/>
      <img src="C:\\FX.jpg" width="300"/>'''
result=re. findall('<img src="(.*?)"', s)
print(result)
```

['C:\\XH.jpg', 'C:\\FX.jpg']

正则表达式示例

```
import re
s=''<img src="C:\\XH.jpg" width="300"/>
      <img src="C:\\FX.jpg" width="300"/>''
result=re.findall('<img src="(.*?)" width="(.*?)"', s)
print(result)
```

[('C:\\XH.jpg', '300'), ('C:\\FX.jpg', '300')]

豌豆荚正则示例

```
page=u'''
<li class="parent-cate">
<a class="cate-link" c>旅游出行</a><ul>
<li class="child-cate"><a href="http://www.wandoujia.com/category/596"
title="综合旅游服务">综合旅游服务</a></li>
<li class="child-cate"><a href="http://www.wandoujia.com/category/598"
title="攻略">攻略</a></li>
<li class="child-cate"><a href="http://www.wandoujia.com/category/600"
title="酒店·住宿">酒店·住宿</a></li>
</ul></li>
'''
```

豌豆荚正则示例

```
#coding=utf-8
import re
page=u'''<li class="parent-cate">
<a class="cate-link" c>旅游出行</a>
<ul><li class="child-cate"><a href="http://www.wandoujia.com/category/596" title="综合旅游服务">
综合旅游服务</a></li>
<li class="child-cate"><a href="http://www.wandoujia.com/category/598" title="攻略">攻略</a></li>
<li class="child-cate"><a href="http://www.wandoujia.com/category/600" title="酒店·住宿">酒店·住
宿</a></li>
</ul></li>
'''
data=re. findall('href="(.*?)" title="(.*?)"', page)
print(data)
```

豌豆荚正则存入文件

```
#coding=utf-8
import re
page=u''' <li class="parent-cate">
<a class="cate-link" c>旅游出行</a>
<ul><li class="child-cate"><a href="http://www.wandoujia.com/category/596" title="综合旅游服务">综合旅游服务</a></li>
<li class="child-cate"><a href="http://www.wandoujia.com/category/598" title="攻略">攻略</a></li>
<li class="child-cate"><a href="http://www.wandoujia.com/category/600" title="酒店·住宿">酒店·住宿</a></li>
</ul></li>
'''
data=re.findall('href="(.*?)" title="(.*?)"', page)
fobj=open("test.txt", "w")
for line in data:
    fobj. write(line[0]+"  "+line[1]+"\n")
fobj. close()
```

思考题一

已知result= re. findall(r'b.*a', 'banana')，则匹配结果是（　）

A ['banana']

B ['ba']

C ['ban']

D ['bana']

思考题二

已知result= re. findall(r'b.*?i', 'www.blibli.com')，则匹配结果是（　）

A ['blibli']

B ['blibli.com']

C ['www.blibli.com']

D ['bli', 'bli']

案例分析

“C:\素材”文件夹中h.txt为已爬取的某新闻网站的静态html文本文件（编码格式为UTF-8），其中新闻链接和标题的呈现特点是“标题”，请利用正则方法，筛选其中新闻链接和标题，保存在C:\KS\news.csv（编码格式为GBK，结果示例如图），程序保存在C:\KS目录下，名为 4_5.py。

1	http://www.ce.cn/xwzx/gnsz/gdxw/202007/24/t20200724_35386699.shtml	中国经济增长重开马力
2	http://www.ce.cn/xwzx/gnsz/gdxw/202007/24/t20200724_35386703.shtml	外贸有所回稳
3	http://news.cctv.com/2020/07/23/ARTIOgdNR4557PJua229m827200723.shtml	2季度货运量正增长
4	http://news.cctv.com/2020/07/23/ARTIuXNPwTxzLI1IRPIz8sjp200723.shtml	工业生产稳步回升
5	https://wap.peopleapp.com/article/5760724/5682238	王小良返乡脱贫记
6	https://3w.huanqiu.com/a/de583b/3zAz3PASXzE?agt=8	“天问一号”中国首次火星探测这四大看点请收好
7	https://wap.gmdaily.cn/article/pb517fcb032b24c93ae0cc43f3d24f44f	遵义:脱贫到致富
8	https://xhpfmapi.zhongguowangshi.com/vh512/share/9272522	乌蒙"同心"战贫困
9	https://wap.gmdaily.cn/article/pfe06986dc832498ba3e1dc7c3c7ae3c4	古胜村逆袭记
10	https://xhpfmapi.zhongguowangshi.com/vh512/share/9272405	甩穷帽子吃"生态饭"
11	http://news.cctv.com/2020/07/23/ARTIp20aylqkJecYvJYprLgz200723.shtml	眉山果园村"幸福密码"
12	http://www.ce.cn/xwzx/gnsz/gdxw/202007/23/t20200723_35381001.shtml	"码上黔行"
13	https://mp.weixin.qq.com/s/rei6k_eVgZO7yRujjrsVxA	关于有不法分子冒用中央网信办举报中心名义开展
14	https://3w.huanqiu.com/a/438198/3zBTsZ7tF7X?agt=8	外交部:美国驻成都总领事馆人员从事与身份不符
15	https://baijiahao.baidu.com/s?id=1673081065892684209&wfr=content	央视实拍美驻成都总领馆：门前市民熙攘 院内情

(.*?)

案例分析

```
import re
fobj=open("C:\\素材\\h.txt","r",encoding="utf-8")
paper=fobj.read()

reg=r'<a href="(http://.*?)" mon="ct=1&amp;a=2&amp;c=top&pn=\d{1,2}"
target="_blank">(.*?)</a>'
result=re.findall(reg,paper)

fobj=open("C:\\KS\\news.csv", "w")
for line in result:
    fobj. write(line[0]+","+line[1]+"\n")
fobj. close()
```

爬取新浪财经链接和标题

```
import requests
import re
url="http://finance.sina.com.cn"
html=requests. get(url)
html. encoding=html. apparent_encoding
data=html. text
#print(data)
```

爬取新浪财经链接和标题

```
reg=r'<a href="(.*?)" .*?\d{2}">(.*?)</a></li>'
urls=re.findall(reg, data)
print(urls)
fobj=open("result.csv",'w', encoding="gb2312")
for titu in urls:
    fobj.write(titu[0]+","+titu[1]+'\n')
fobj.close()
```

数据清洗常见方法

- 用strip()函数删除空格及换行符等非相关符号

```
>>> res='  华能信托本年实现利润32.05亿元  '
>>> res=res.strip()
>>> res
'华能信托本年实现利润32.05亿元'
```

数据清洗常见方法

- 用split()函数截取需要的内容

```
>>> date='2019-01-20 10:10:10'
>>> date=date.split(' ')[0]
>>> date     '2019-01-20'
```

数据清洗常见方法

- 用sub()函数进行内容替换

短语标签，用来呈现为被强调的文本

```
>>> import re
>>> title='阿里<em>巴巴</em>人工智能再发力'
>>> title=re.sub('<.*?>', '',  title)
>>> title     '阿里巴巴人工智能再发力'
```

思　考

```
import re
res = '<h3 class="c-title"><a href="网址" data-click="{一堆英文}"><em>阿里巴巴</em>代码竞赛现全球首位AI评委 能为代码质量打分</a>'
p_title = '<h3 class="c-title">.*?>(.*?)</a>'
title = re.findall(p_title, res)
print(title)
```

['阿里巴巴代码竞赛现全球首位AI评委 能为代码质量打分']

解决方案

```
import re
title  =  ['<em>阿里巴巴</em>代码竞赛现全球首位AI评委能为代码质量打分']
result = re.sub('<.*?>', '', title[0])
print(result)
```

阿里巴巴代码竞赛现全球首位AI评委 能为代码质量打分

爬取新浪财经链接和标题（修订）

```
reg=r'<a href="(.*?)" .*?\d{2}">(.*?)</a></li>'
urls=re.findall(reg, data)
fobj=open("result.csv",'w', encoding="gb2312")
for titu in urls:
    new=re.sub('<.*?>',"",titu[1])
    fobj.write(titu[0]+","+new+'\n')
fobj.close()
```

爬取小米官网多个文件

```
import requests
import re
url='https://ir.mi.com/zh-hans/financial-information/quarterly-results'
r=requests. get(url)
r. encoding=r. apparent_encoding
paper=r.text
cond='<a href="(.*?.pdf)" type="application/pdf" title='
urls=re. findall(cond, paper)
print(urls)
```

爬取新闻图片素材

```
x=0
for img in urls:
    address='https://ir.mi.com/'+img
    print(address)
    r=requests.get(address)
    fobj=open("E:\\result\\"+str(x)+".pdf",'wb')
    fobj.write(r.content)
    x+=1
```

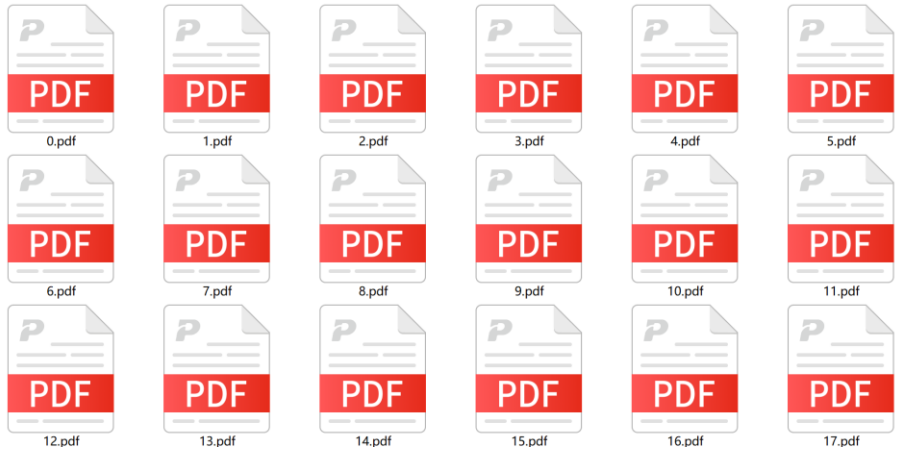

谢　谢