



# 第12课 人工智能伦理

当技术拥有“判断力”

# 人工智能伦理：不是一门技术，而是一种价值

## 我们关注的核心

✗ 不是  
算法精度达到了多少

✓ 而是  
算法背后的价值取向是  
什么

✗ 不是  
技术如何实现

✓ 而是  
技术对社会、生活、个  
人的影响



## 本质

科技与人文的深度对话，  
探讨技术与人类价值的平衡。

# 破冰思考：几个问题，开启我们的思考



## 01. AI能替老师阅卷吗？

### 正方观点：

评分标准统一，规避人为偏差；效率极高，可快速完成海量试卷批改。

### 反方观点：

缺乏情感共鸣与人文关怀，难以评判发散性思维与深度创造，容易扼杀学生的想象力。



## 02. AI招聘歧视，谁负责？

- 算法开发者？是否在模型设计中植入了潜在偏见？
- 数据提供者？训练数据是否本身就带有历史的歧视性特征？
- 公司管理者？在部署使用前，是否履行了充分的审核与监管责任？



## 03. 技术发展有边界吗？

**“我们应该追求一切可能实现的技术吗？”**

技术的上限不应仅仅取决于“能不能”，更取决于“该不该”。伦理与道德，应当成为技术发展的刹车与方向盘。

# 课堂投票：你认为AI是？

## A 中性的工具

技术本身并无好坏之分，其影响完全取决于使用者的意图和使用方式。AI就像一把刀，可以用来做手术救人，也可以用来犯罪。

## B 自带价值倾向的系统

从算法逻辑的设计，到训练数据的筛选与标注，都不可避免地嵌入了人类的价值观、社会偏见与伦理取舍，因此AI系统不可能保持绝对中立。

# 从“工具”到“决策主体”的伦理革命



## 弱人工智能

(当前主流阶段)

专注于执行单一领域的特定任务，不具备真正的自我意识。本质上是人类的辅助工具，旨在增强和补充人类的决策能力。

。

典型案例：语音助手、图像识别技术、推荐算法等。



## 强人工智能

(未来终极构想)

拥有与人类相当的感知、推理、学习和解决问题的综合能力，具备意识和主观体验，能独立进行复杂的价值判断。

典型案例：《西部世界》、《终结者》等科幻作品中的通用型机器人。

。



## 关键伦理转变

从“辅助”走向“决策”

今天的伦理挑战并非源于遥不可及的“强人工智能”，而是当下的AI系统正在接管大量对人类生活有深远影响的重要决策权：

- 信贷审批与保险费率评估
- 企业招聘与简历筛选
- 司法量刑与假释辅助
- 教育资源分配与升学分流

# 为什么今天必须讲AI伦理？

01

数据隐私

隐私被持续商品化，  
我们成为数据的“产品”。

02

算法公平

算法黑箱遮蔽公正，  
系统性歧视加剧社会不公。

03

AIGC

深度伪造模糊真假边界，  
社会信任被侵蚀。

04

责任归属

自主系统扩大人类权力，  
但责任链条断裂。

05

数字鸿沟

技术发展加剧阶层、  
区域、群体间的不平等。

科技创新不能没有价值罗盘，数字时代不能失守人文底线。

# 什么是人工智能伦理？

**定义** | 人工智能伦理是研究AI在研发、应用、治理等各个环节中，关于**责任、权利、风险的价值规范体系**。它不仅关注技术发展的可行性，更关注技术对人类社会、个体权益及长远发展的影响与约束。



## 行动准则追问

技术能力上的“可以做什么”



社会伦理上的“应当做什么？”



## 价值判断追问

技术物理属性的“能不能实现”



道德哲学上的“该不该做？”



## 价值排序追问

商业逻辑的“效率优先”

VS

人类社会的“公平/安全/人权优先？”

# AI伦理的三大研究层面

## 01 研发伦理

### 主体

设计者、工程师、企业

### 核心议题

技术设计中的价值嵌入、风险评估与安全保障体系的构建。

## 02 应用伦理

### 主体

终端用户、运营平台、社会公众、政府监管部门

### 核心议题

确立使用行为规范，分析技术的社会影响，完善公共治理框架与明确法律责任归属。

## 03 存在伦理

### 主体

全人类与未来的智能生命共同体

### 核心议题

探讨人与机器、人工智能、生命本质以及人类文明演进之间的根本关系与终极意义。

# 一个危险的误区：反思“技术中立论”

技术并非中立，因为：



## 算法由人设计

设计者的价值观、偏见与认知局限，都会以代码形式嵌入算法逻辑之中。



## 数据由人采集

数据来源的选取、样本的界定本身就带有主观视角，输入即可能带有偏见。



## 目标由人设定

在商业环境下，技术的优化目标往往优先服务于资本增值，而非公共利益。




## 收益由人分配

技术带来的社会与经济红利，在分配机制上往往呈现显著的不平等特征。

**核心结论：没有中立的技术，只有中立的责任逃避。**

# 案例警示：技术不中立的证据



## 01 / 招聘AI歧视女性

问题根源：


训练数据集中女性高管的样本数量严重不足，导致算法在学习过程中，无意识地继承并放大了人类社会中长期存在的性别偏见。



## 02 / 画像系统标签化弱势群体

问题根源：

人工数据标注环节中，标注员的主观刻板印象与偏见被数据化，进而被算法逻辑固化、标准化，并在大规模应用中被不断放大。



## 03 / 推荐算法放大极端情绪

问题根源：

商业平台将算法的核心目标设定为“最大化用户停留时间”以获取流量，而非“促进公共理性讨论”，导致算法主动迎合人性弱点，不断推送极端化、情绪化的内容。

# AI伦理的基本价值立场

我们共同的价值基石，也是全球共识的方向：



## 以人为本

以人类福祉为根本出发点，确保AI技术始终服务于人，促进人的全面发展。



## 公平公正

消除算法偏见与歧视，保障不同性别、种族、群体在AI应用中享有平等的权益。



## 透明可控

AI决策逻辑可解释、过程可追溯，始终确保人类对关键技术的最终决策权。



## 安全可靠

强化技术风险防控，防范滥用误用，确保AI系统的稳定性与安全性底线。



## 权责清晰

明确AI研发、生产、应用全链条的责任主体，建立健全可落地的责任追究机制。



## 包容普惠

降低技术门槛，缩小数字鸿沟，让不同地域、不同群体都能共享AI发展的红利。



智能可以迭代，伦理不能失守