

第12课 AI伦理与治理的哲学根基

从理论思辨到制度建构

COURSE 12 · AI Ethics

课程目录

CONTENTS

01

课程导入

当AI重塑世界，我们该如何划定技术的边界？

02

哲学溯源

多元思潮的伦理启示

03

伦理困境解析

核心伦理困境的哲学解析

04

治理体系建构

从哲学思辨到实践落地

05

案例研讨

自动驾驶的伦理与治理实践

06

文献解读

《生命3.0》与《人工智能治理白皮书》

07

总结与作业

核心要点回顾与课后任务

01 课程导入：当AI重塑世界，我们该如何划定技术的边界？

核心问题：技术之上，何以为界？

- 当AI拥有自主决策能力并全面渗透社会方方面面，我们该如何为其划定不可逾越的伦理边界？
- 如何构建透明、公正且高效的治理机制，确保AI技术始终服务于人类的共同利益与长远福祉？



理性主义

从逻辑与规则出发，为AI伦理准则的确立提供严密的逻辑框架与理性依据。



实用主义

以实际效用与社会后果为导向，为AI治理的具体目标和评估标准指明方向。



后现代主义

解构技术的“中立性”神话，揭示AI发展与治理过程中潜在的权力、文化与价值的核心矛盾。



东方哲学

引入“天人合一”与“中庸之道”，为构建平衡、和谐、可持续的AI治理模式提供价值锚点。

01 课程导入：本课程脉络



核心问题：

不同哲学思潮如何为AI伦理与治理提供理论支撑？如何将哲学思辨转化为可落地的治理制度？



AI伦理的哲学溯源

探索多元哲学思潮如何为AI伦理提供深层启示，寻找技术背后的价值根基。



核心伦理困境的哲学解析

运用哲学分析工具，深入拆解算法歧视、隐私泄露、责任认定等现实技术伦理难题。



治理体系的制度建构


探讨如何将抽象的哲学思辨转化为可执行、可落地的技术标准与治理制度。

02

AI伦理的哲学溯源

多元思潮的伦理启示

理性主义：普遍伦理准则的逻辑基础



☒ 核心启示：先天理性与普遍客观

理性主义认为道德准则源于先天理性而非后天约定，具有客观必然性。这意味着在AI领域，应存在跨越文化、地域与意识形态的普遍伦理底线。



不伤害人类

物理与心理双
重安全



尊重人类尊严

拒绝歧视与工具
化



保障隐私

数据所有权
不可侵犯



自动驾驶场景

“优先保护行人安全”是基于理性推演的不可逾越的伦理底线，不随算法优化妥协。



医疗AI场景

“不泄露患者隐私”是必须遵守的客观规则，不受商业利益或效率因素的外部干扰。

实用主义：伦理准则的实践导向

核心启示：效果与价值

实用主义哲学的核心在于以“**实际效果**”与“**社会价值**”作为评判伦理准则的最终依据，而非固守抽象原则。

AI伦理不应是脱离现实的“空中楼阁”，必须扎根于技术落地的真实土壤，解决实际问题，回应真实需求。

核心判断标准

可行性



(Feasibility)

伦理准则需具有落地基础

有效性



(Validity)

解决问题并产生正向价值

伦理落地的关键路径



因地制宜


发展中重“普惠”
发达国重“防异化”



动态调整

定期评估社会影响
持续修正完善准则

后现代主义：伦理治理的批判性视角



● 核心启示：解构权力与建构性

后现代主义揭示了技术伦理并非“中立”，而是被技术精英、资本集团等权力主体所建构的产物。其核心在于解构AI伦理背后隐藏的权力结构与潜在的社会不平等问题。



核心原则：多元参与

打破单一视角垄断，汇聚不同群体的声音与诉求



伦理实践：打破准则制定的垄断

制定准则时必须引入技术人员、伦理学家及**弱势群体代表**共同参与。

例：制定招聘算法伦理，需邀请女性、非名校生参与，规避歧视。

东方哲学：伦理治理的和谐目标



核心启示：人机和谐，共生共荣

以“天人合一”与“和而不同”为思想内核，伦理治理的终极目标既非“控制AI”，亦非“放任AI”，而是实现技术与人文在伦理维度上的有机融合与平衡发展。

和谐共生

技术进步不应以牺牲人文价值为代价，寻求人类社会与AI生态的共存共荣。

中庸之道

避免治理的两个极端，在发展与规范、效率与公平之间寻找最佳平衡点。

动态平衡关系

自动化兼顾就业稳定，智能监控兼顾隐私保护，不以偏概全。

严守伦理边界

明确技术应用的范围与底线，避免因技术滥用侵犯公民基本权利与自由。


The background is a dark blue field filled with a complex network of thin, light blue lines that intersect to form various geometric shapes, including triangles and polygons. Two larger, more prominent wireframe structures resembling crystalline or molecular models are positioned on either side of the central text. The overall aesthetic is futuristic and technological.

03

AI核心伦理困境的哲学解析

PHILOSOPHICAL ANALYSIS OF AI CORE ETHICAL DILEMMAS

算法歧视：权力结构与数据偏见的双重叠加



📖 哲学解析：从历史与价值观视角审视

- **后现代主义视角**：算法歧视是社会权力结构的技术化投射，历史数据中的隐性偏见被算法模型“理性”固化，进一步强化了既有的社会不平等。
- **东方哲学视角**：违背“和而不同”的多元价值观，将单一评价标准强加于异质化的社会群体，破坏了社会的包容性与和谐共生的基础。

☂️ 破局之道：技术、伦理与治理的协同

- **技术修正**：采用数据去偏预处理技术与算法公平性约束机制，在模型训练阶段消除历史数据偏差。
- **多方共治**：引入社会多元主体参与算法设计与审查，建立透明化的算法伦理审查与问责机制。

隐私泄露：技术便利与权利保护的价值冲突

哲学解析

理性主义视角·伦理底线

隐私是人类不可剥夺的基本权利。在AI技术发展的过程中，“保障隐私安全”是必须坚守的普遍伦理底线，不可为技术便利而让渡人的尊严。

实用主义视角·平衡之道

隐私保护与技术便利并非天然对立。通过合理的技术与制度设计——如“数据匿名化”处理、分布式“联邦学习”技术，完全可以实现两者的动态平衡。

解决思路

技术层面：隐私计算技术



突破传统数据流转模式，实现“数据可用不可见”，从源头切断泄露风险。

伦理层面：确立“最小化原则”



AI应用仅采集和使用实现功能所必需的最少数据，从商业逻辑上减少隐私暴露面。

治理层面：法律与制度建设



完善并严格执行数据保护法律法规，明确责任主体，加大违规成本。

责任认定：人机协作中的伦理模糊地带

哲学解析·溯源与导向

佛家“缘起性空”视角



AI的“智能”本质上是算法、数据、算力等条件“因缘和合”的产物，本身不具备自我意识与自由意志。因此，无论AI表现如何，人类作为设计者和使用者，应对其行为负最终责任。

实用主义视角：效果导向



责任认定不应仅纠结于“谁”，更应关注“效果”。其核心目的是通过清晰的责任划分，建立可预期的激励与约束机制，引导各方遵守伦理准则。



构建多方协同的责任体系

明确责任链条

开发者、使用者、监管者权责分明，各司其职


建立技术追溯

利用“算法日志”等手段，记录决策全过程

完善法律框架

将AI责任认定纳入现有法律体系，填补空白

技术异化：人类与技术的主客关系倒置



📦 哲学解析·根源追溯

| 现象学视角：人机关系发生“主客倒置”，AI从“上手”的工具异化为“现成”的支配者，不断消解人类的主体性。

| 东方哲学视角：违背“天人合一”的整体观，将人与技术二元对立，打破了本该共生共荣的和合关系。

☂️ 破局之道·多维应对

伦理锚点：确立“人类主导、AI辅助”的协作底线，防止技术凌驾于人类价值之上。

能力重塑：强化数字素养教育，培育独立思考能力，避免对AI的盲目依赖。

制度约束：在医疗、司法、金融等关键决策领域，建立AI应用的“负面清单”与问责机制。


04

AI治理体系的制度建构

从哲学思辨到实践落地

治理主体的多元性：打破技术精英的话语权垄断

 **核心理念（源于后现代主义）**：AI治理不能由技术精英或资本集团单方面主导，而应建立多元主体参与的治理机制，汇聚各方智慧与力量，确保技术发展符合人类共同利益。



政府·监管引导

作为规则制定者，完善法规体系，实施宏观监管与引导。



企业·主体责任

将伦理准则嵌入研发全周期，确保技术安全与合规。



学术界·理论支撑

开展理论与研究预警，提供坚实的智力与技术支持。




公众·参与监督

通过多元渠道参与治理制定，监督治理落实。

治理层次的系统性：覆盖AI发展的全生命周期

核心理念（源于实用主义）：AI治理不能局限于单一环节，必须贯穿研发、测试、部署、运维的全生命周期，通过分层治理构建无死角的防护网。



研发：伦理审查

在算法设计与数据采集源头，建立伦理审查与风险评估机制。



测试：多场景验证

开展极端、边缘、多样化场景的伦理与功能测试。



部署：准入与备案


建立严格分级分类准入制度，实行强制性备案。



运维：动态监测

建立全生命周期动态监测系统，快速响应风险。

治理机制的动态性：适应技术发展的变化需求



核心理念·源于东方哲学

AI治理不能墨守成规，而应建立动态调整的机制，在快速迭代的技术浪潮与复杂多元的人文关怀之间，找到可持续发展的平衡点。



定期评估机制

每1-2年对伦理准则与治理制度进行系统性的评估与修订。



国际协作机制

加强全球范围的交流协作，共同制定跨国界的AI伦理标准。



应急响应机制

针对突发的技术滥用或伦理风险，建立快速反应与干预体系。

05

案例研讨

自动驾驶的伦理与治理实践

案例背景与研讨问题

01 / 案例背景

随着人工智能技术的飞速发展，自动驾驶已从科幻想象逐渐走向现实应用。然而，这项颠覆性的技术在带来便利的同时，也给人类社会带来了前所未有的**伦理与治理挑战**。

其中最典型的包括经典的“电车难题”式道德困境、事故发生后的法律责任认定难题，以及在技术快速迭代的过程中，如何在追求极致创新与确保公共交通安全之间找到平衡点，都是亟待解决的核心议题。

理性主义视角

为何“优先保护行人”应当成为自动驾驶算法不可逾越的伦理底线？

后现代主义视角

在算法黑箱之下，如何避免技术精英与车企形成“伦理独裁”，导致话语权的垄断？

东方哲学视角

借鉴“中庸之道”，在追求自动驾驶的技术效率与保障公共道路安全之间，如何寻求最佳平衡点？

多元治理理念

政府、企业、学界与公众应如何协同，构建一个兼顾创新活力与社会公平的自动驾驶治理体系？

研讨总结：多元哲学的融合应用

自动驾驶的伦理与治理，是多元哲学思潮融合应用的典型案例。

理性主义

提供“优先保护行人”的普遍伦理底线，为技术应用确立不可逾越的道德基准。

后现代主义

要求打破技术与准则制定的垄断，吸纳多元社会主体共同参与伦理规则的构建。

东方哲学

以“中庸之道”指导实践，在技术激进创新与道路交通安全之间寻找最佳平衡点。



治理体系构建结论：


构建自动驾驶的治理体系，需要政府、车企、学术界、公众等多方主体协同发力，贯穿技术研发到运维的全生命周期，才能实现技术与人类福祉的有机统一。

06

文献解读

《生命3.0》与《人工智能治理白皮书》

核心观点提炼



📖 《生命3.0》 | 迈克斯·泰格马克 (Max Tegmark)

💡 **核心观点**：AI发展不应由技术单向驱动，而应由人类的价值目标驱动，必须主动“为AI设定目标”。

🔗 **哲学关联**：既契合实用主义的“效果至上”逻辑，又与东方哲学中“向善而行”的伦理追求不谋而合。

📄 《人工智能治理白皮书》 | 中国信息通信研究院

🎯 **核心原则**：坚持“以人为本、公平公正、透明可追溯、安全可控”。

🏛️ **治理框架**：构建“政府引导、市场主导、社会参与”的协同治理格局。

🌐 **哲学关联**：充分体现了集体主义、规则意识与多元包容哲学思潮的融合。

文献启示：哲学思辨 → 伦理准则 → 治理制度



哲学思辨

《生命3.0》的启发

立足人工智能对人类社会、生命本质的长远影响，为AI发展提供根本性的哲学思考，奠定伦理基石。



伦理准则

连接理论与实践的桥梁

将抽象的哲学思考转化为可理解、可认同的行为准则与价值取向，回答“应该如何做”的道德追问。



治理制度

《人工智能治理白皮书》

提供具体的政策指引与实施框架，将软性的伦理共识转化为硬性的治理规范与制度保障。

核心启示：这种“哲学深度思考 + 政策制度落地”的融合模式，构成了AI健康发展的完整逻辑闭环。

The background is a dark blue field filled with a complex network of thin, light blue lines that intersect to form various geometric shapes, including triangles and polygons. Two larger, more prominent wireframe structures resembling crystalline or molecular models are positioned on either side of the central text. The overall aesthetic is futuristic and technical.

07

课程总结与课后作业

COURSE SUMMARY & HOMEWORK

核心要点回顾



理性主义

为AI伦理确立逻辑框架与基本原则，提供不可逾越的普遍底线与准则。



实用主义

强调治理措施的现实可行性与实际效果，确保理论与产业实践紧密结合。



后现代主义

警惕技术霸权与单一视角，倡导多元主体参与、去中心化的协商与对话。



东方哲学

以“天人合一”与“中庸之道”为指引，指明人机协同、社会和谐的终极目标。



核心路径：从思辨到制度

只有将深刻的哲学思辨转化为可落地的法律法规、行业标准与企业准则，构建完整的制度体系，才能真正实现AI技术的健康、安全与可持续发展。

课后作业

作业 题目

《XX场景下的AI伦理困境与治理路径研究》



01 / 场景选取

选取一个具体的AI应用场景进行切入，例如：自动驾驶、智能招聘、医疗AI诊断、推荐算法等。



02 / 困境分析

深度剖析该场景下AI技术落地面临的核心伦理冲突与现实困境，需具体而非泛泛而谈。



03 / 哲学解析

运用课程所学的至少两种哲学思潮的理论工具对上述困境进行根源性解析。



04 / 治理路径与制度建议

基于多元协同治理理念，结合场景特性提出可操作的伦理治理方案与制度设计建议。

Q & A

互动与答疑